


ZIO AI Appliance

- 모델명: ZIO AI CLUSTER Appliance “**ZAC-10-N4**”
- Node 4개로 클러스터 구성 (클러스터 기본 단위)
 - Kubernetes
 - HA Proxy
 - WAF (웹방화벽)
 - master node + worker node
- VRAM : 128 GB * 4개 = 512 GB
- DISK : DGX Spark (4TB * 4 = 16TB), AMD Ryzen AI 395 (2TB * 4 = 8TB)
- Software
 - Linux, MSA(Micro Service), CICD, docker containers
 - zio agentic ai, 8개의 docker container 기본구성
 - local LLM's
 - LLM Serving Framework
 - basic Tools 20개, ontology store
 - RAG Retrieval

ZIO.AGENT CLUSTER
Appliance “ZAC-10-N4”



MSA software stack




Client Web (React), CLI				
API Server	Agent Protocol API		Tools	MCP, Skills
AV-Engine	Yara-Engine	URL-Scanner	CDR-Worker	Cron-Jobs
Ollama	LMStudio	vLLM	SGLang	SGLang
REDIS	PostgreSQL	PostgreSQL	GraphDB	MongoDB
Linux Ubuntu 24.04				

Local LLMs (기본 장착)

Vendor	Model	Parameters	주 용도
Google	Gemma4	26b	낮은 성능의 추론용
OpenAI	gpt-oss-20b	20b	기본 모델 (수집 및 분류)
Alibaba	qwen/qwen3-v1-8b	8b	Intent 파악 용
ZioYou	zio/text-to-knowledge-Gemma-3-27B-Instruct-2025.11.0	27b	지식그래프 쿼리용
	domain specific LLM Fine Tuning	26b	implementation

zio/text-to-knowledge-Gemma-3-27B-Instruct-2025.11.0



1. 강력한 기반 모델: Gemma 3 27B

○ **멀티모달 및 긴 문맥**: Gemma 3는 텍스트와 이미지를 동시에 처리하며, 최대 **128K** 이상의 컨텍스트 윈도우를 지원합니다. 이를 통해 방대한 지식 베이스를 참고해야 하는 작업에서 유리한 고지를 점합니다.

○ **지능적 추론**: 27B 파라미터 규모는 복잡한 논리 구조를 이해하고, 자연어 질문 속에 숨겨진 의도를 정확히 파악하여 쿼리로 변환하는 데 최적화된 크기입니다.

2. 학습 특화: Text-to-Query (T2Q)

○ **데이터 규모**: 35,000쌍의 데이터셋은 일반적인 지시어 학습을 넘어, ****지식 탐색 전용 언어 (SQL, Cypher, API Query 등)****를 생성하는 데 필요한 패턴을 충분히 학습할 수 있는 규모입니다.

○ **정확도 중심**: 단순한 자연어 생성이 아니라 "지식 탐색의 정확도"와 "효율성"에 초점을 맞춘 포스트 트레이닝을 거쳤으므로, 환각(Hallucination) 현상을 줄이고 실질적인 정보 추출 성능을 극대화했을 것으로 보입니다.

3. 주요 활용 시나리오

○ **에이전틱 RAG (Agentic RAG)**: 사용자의 모호한 질문을 분석하여, 지식 베이스(Vector DB, Graph DB 등)에 던질 최적의 검색 쿼리를 스스로 생성합니다.

○ **복잡한 지식 인출**: 여러 단계의 추론이 필요한 질문에 대해, 단계별 지식 탐색 경로를 설계하고 실행 가능한 쿼리를 만듭니다.

○ **엔터프라이즈 지식 관리**: 사내 문서나 데이터베이스에서 비전문가도 자연어로 정확한 데이터를 뽑아낼 수 있는 인터페이스 역할을 수행합니다.

RLHF vs DPO

DPO (Direct Preference Optimization)

AI 모델이 A라는 답변과 B라는 답변 중 어떤 것이 사람이 선호하는(정확한) 답변인가? 를 직접 학습하게 만드는 최신 알고리즘

기존 방식 (RLHF)	AI를 학습시키려면 ‘보상 모델(Reward Model)’이라는 중간 채점자를 따로 만들어서 복잡하게 가르쳐야 했음. 과정이 매우 어렵고 자원도 많이 소요됨	정렬 파인튜닝 (Alignment Fine-tuning)
DPO 방식	중간 채점자 없이, ‘.. 이 쿼리가 저 쿼리보다 나아’라는 데이터셋을 모델에 직접 주입하여 학습. 훨씬 빠르고 안정적으로 AI의 성능을 높일 수 있는 기술	

ZAC-10-N4에서 DPO가 중요한 이유

우리가 정의한 ‘T2Q 엔진’의 핵심은 사용자의 질문을 데이터베이스 언어인 ‘Cypher(쿼리)’로 정확히 바꾸는 것입니다.

사용자가 “지난달 매출 보여줘”라고 했을 때, AI가 2가지 쿼리를 만들었다면

- A쿼리: 실제 매출 데이터를 정확히 인출하는 쿼리 (선호)
- B쿼리: 문법은 맞지만, 보안상 위험하거나 엉뚱한 데이터를 건드리는 쿼리 (비선호)

학습결과: DPO 기술을 적용하면 AI가 “B보다는 A가 실무에 적합한 정답이다”라는 것을 직접 학습하게 되어, 최종적으로 98% 이상의 초고정밀 정확도를 확보 가능

Self Fine-Tuning (숙련된 우리회사 업무장인)

사례. ERP/MES 제조 공정 특화 수치 예측 모델

1. 모델 개요 "Coating Quality Prediction Model"

- **모델아키텍처**: GPU 가속기반의 XGBoost (Extreme Gradient Boosting) 기반의 앙상블 모델
- **목표**: 코팅 공정의 숙련 장인이 가진 '감(Intuition)'을 수치화된 지능으로 변환하는 것을 목표
- **핵심 기능**: 5대 공정 변수(온도, 압력, 속도, 장력, 습도)를 분석하여 최종 제품의 두께를 예측하고 불량 리스크를 산출.
- **목표 지표**: \$RMSE\$ 최소화 및 \$R^2\$ Score 0.85 이상 확보.

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$$

2. 개발 도구 및 환경 (Tech Stack)

- 언어 및 라이브러리: Python 3.10, Scikit-learn, XGBoost, 정형 데이터 처리에 최적화된 스택
- 데이터 처리: Pandas, NumPy, Dask, 35TB 대규모 데이터의 병렬 처리
- 인프라: Linux Ubuntu 22.04, NVIDIA RTX 3080 GPU, GPU 가속(CUDA)을 통한 학습 속도 향상
- 시각화/분석: Matplotlib, SHAP, WandB, Feature Importance 분석 및 실험 관리

3. 단계별 개발 과정 (Workflow)

Step 1: 데이터 추출 및 엔지니어링 (Data Engineering)

- **데이터 로드**: 35개 설비(Coating #1, #2 등)에서 수집된 시계열 데이터(1초 단위) 로드.
- **시계열 정렬 (Alignment)**: 배합-코팅-속성으로 이어지는 공정 간의 ****Lag-time(지연 시간)****을 계산하여 LOT 단위로 데이터를 동기화.
- **특성 추출 (Feature Engineering)**: 단순 센서값 외에 '이전 존(Zone)과의 온도 차이', '장력 변동 계수' 등 도메인 지식이 반영된 파생 변수 생성.

Step 2: 전처리 및 스케일링 (Preprocessing)

- **결측치/이상치 처리**: 센서 노이즈 및 가동 중단 구간 데이터 제거.
- **스케일링**: * StandardScaler: 온도, 속도 등 정규분포에 가까운 변수 적용.
- **MinMaxScaler**: 습도, 압력 등 일정 범위 내 변수 적용.
- **데이터 분할**: 시계열 특성을 고려하여 과거 데이터(70%)는 학습, 최근 데이터(30%)는 검증 및 테스트로 분할.

Step 3: 모델 학습 및 튜닝 (Modeling & Tuning)

- **하이퍼파라미터 최적화**: * max_depth=6: 과적합 방지.
- learning_rate=0.1: 안정적인 수렴.
- n_estimators=200: 부스팅 반복 횟수 설정.
- **GPU 가속**: tree_method='gpu_hist' 설정을 통해 대용량 데이터 학습 시간 단축.

Step 4: 성능 평가 및 XAI 분석 (Evaluation & XAI)

- **정량 평가**: \$RMSE\$, \$MAE\$를 통해 실제 두께와 예측값 간의 오차 분석.
- **원인 분석 (SHAP/Feature Importance)**: 어떤 변수가 품질에 기여했는지 분석하여 에이전트가 "습도 대비 온도의 영향력이 70%입니다"라고 설명할 수 있는 근거 마련.

4. 배포 및 유지보수 (Deployment)

1. **Model Serving**: 학습된 모델을 Pickle/Joblib 형태로 저장 후 API 서버(FastAPI 등)로 배포.
2. **Monitoring**: 실시간 센서 데이터 입력 시 품질 예측값을 1초 이내에 반환.
3. **Retraining**: 공정 환경 변화(계절, 노후화)에 따라 1개월 주기로 신규 데이터를 포함하여 재학습(Incremental Learning).

노드 구성 선택 (복합구성 가능)



DGX Spark GB10



AMD Ryzen AI Max+ 395

Node 1

()

()

Node 2

()

()

Node 3

()

()

Node 4

()


()

Type 선택 (택1)

() 19인치 4U



() 10인치 8U



Cost (2026. 04)

선택	Item	Spec	Qty	단가	금액
	NVIDIA DGX Spark	128GB, 4TB	?/4	7,824,000	?
	AMD Ryzen AI 395	128GB, 2TB	?/4	5,577,900	?
	19인치 Rack Case	19 inch frame	2	500,000	1,000,000
	10인치 Rack Case Box	10 inch frame 8단 Rack 7인치 모니터 10port 10G hub	1	600,000	600,000
	ZIO AI Cluster Software	ZIO AI Agents Cluster, Ontology	1	30,000,000	0 (2026. 2분기까지 무료)

Hardware Compare

구분	NVIDIA DGX Spark (128B)	NVIDIA RTX 4090	AMD Ryzen AI Max+ 395
아키텍처	Blackwell (GB10)	Ada Lovelace	Zen 5 + RDNA 3.5
코어 수	6,144개 (CUDA)	16,384개 (CUDA)	2,560개 (Stream)
VRAM	128GB (통합)	24GB(전용 GDDR6X)	128GB (통합)
메모리 대역폭	273 GB/s	1,008 GB/s	500 GB/s (LPDDR5X-8000)
최대 모델 용량	120B ~ 200B+	13B ~ 30B	120B
AI 연산 (FP4)	1,000 TOPS (PetaFLOP)	미지원 (FP8 중심)	지원 (MXFP4 최적화)
가격 (2026년 1월)	740 만원	700 만원	480 만원
의견	전문 AI 개발자용	여러장을 꼽아 사내 서비스용	전문 AI 개발자용

Cost effectiveness

MS-S1 MAX 4-Node AI Cluster vs. 5U RTX 5090 GPU Server

Scenario: Running DeepSeek 671B Q4 Large Language Model

Indicator	MS-S1 MAX 4-Node AI Cluster	5U RTX 5090 GPU Server
Can it run the 671B Q4 model?	 YES	No Requires multiple machines
Volume	 ≈ 35 L ↓ 50%	$\approx 80+$ L
Total Power Consumption	 ≈ 0.72 kW ↓ 80%	$\approx 4-5$ kW
Total Cost	 $\approx \$9.6$ K ↓ 77%	$\approx \$42$ K
Applicable Scenarios	Office / Laboratory (more flexible)	Must be in a data-center environment